Залізо

RAM	VRAM	пропускна здатність пам’яті
64.0 GB	16GB	~100+ GB/S / 6800 MT/s

Розрахунок

Рахую різні квени:

Квантизація	**Q**	**Ваги (P·Q/8)**	**O = 0,2**	**O = 0,3**	**Влазить?**
FP16	16	15,2 GB	~18,3 GB	~19,8 GB	ні
Q8_0	8	7,6 GB	~9,1 GB	~9,9 GB	так
Q4 (int4)	4	3,8 GB	~4,6 GB	~4,9 GB	так, із великим запасом

7B Q8_0: ~10 GB, вміщується.

14B Q4: 14,8 × 0,5 × 1,3 ≈ 9,6 GB, вміщується.

14B Q8: 14,8 × 1 × 1,3 ≈ 19,2 GB, не вміщується.

32B Q4: 32,8 × 0,5 × 1,3 ≈ 21 GB, не вміщується (потрібен офлоад у RAM).

Обрана модель, квантизація й рантайм і чому:

Обрав qwen2.5:7b тому що він є досить ефективним і мало важить

Використовував стандартну дефолтну квантизацію Q4_K_M – в неї найліпший баланс між якістю і швидкістю відповіді

Рантайм - Ollama

Вимірювання до і після оптимізації:

При оптимізації додав reasoning effort = medium

label	**model**	**concurency**	**requests**	**errors**	**ttft_p50_s**	**ttft_p95_s**	**tos_per_p50**	**thros**	**reasoning**
before	qwen2.5:7b	1	16	0	0.023	0.065	115.7	114.2	FALSE
before	qwen2.5:7b	2	16	0	2.047	9.311	120.9	112.9	FALSE

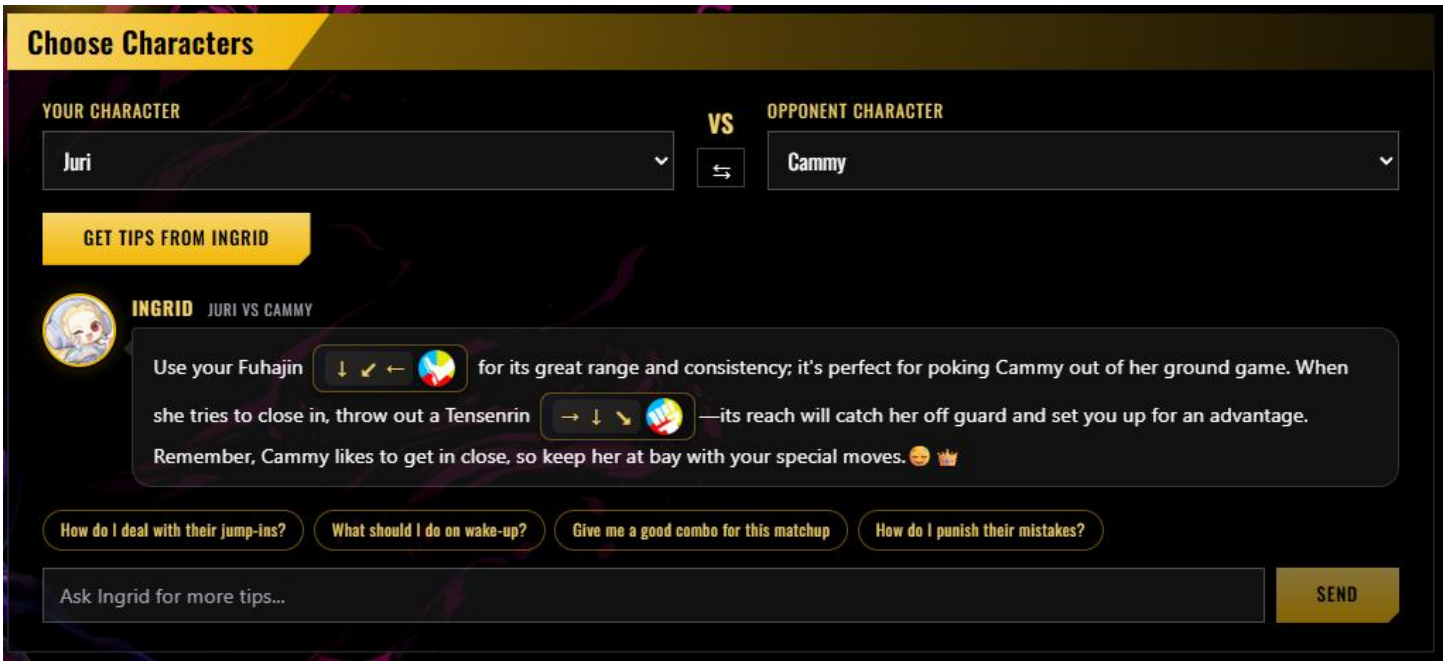
before	qwen2.5:7b	4	16	0	9.058	16.646	122.0	115.8	FALSE
before	qwen2.5:7b	8	16	0	17.418	28.883	109.1	110.2	FALSE
after	qwen2.5:7b	1	16	0	0.018	0.025	120.3	116.0	FALSE
after	qwen2.5:7b	2	16	0	2.437	8.760	121.8	119.4	FALSE
after	qwen2.5:7b	4	16	0	6.776	13.989	120.5	115.4	FALSE
after	qwen2.5:7b	8	16	0	19.444	33.210	112.1	110.8	FALSE

Застосунок — що робить і як працює, параметри генерації:

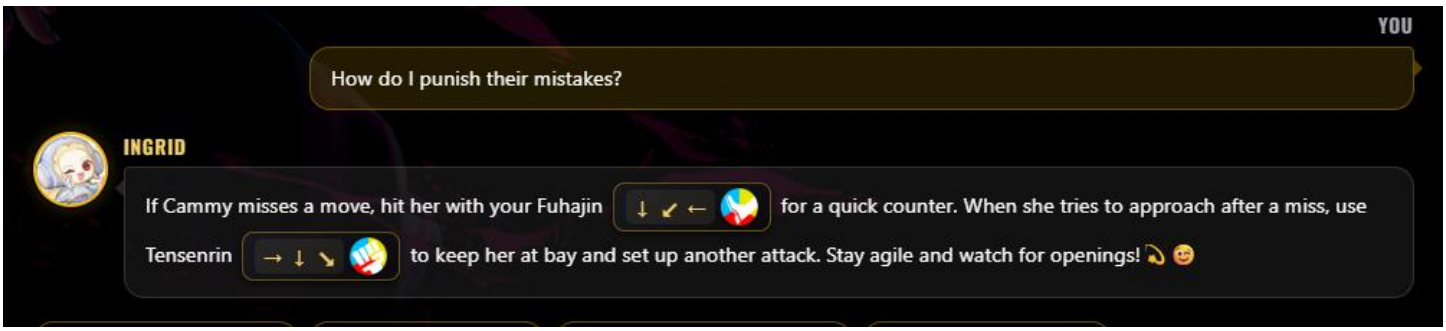
Застосунок це гібридний додаток .NETMAUI Blazor на тематику порадника для комп’ютерної гри Street fighter 6. Його Агент Інгрід дає поради по грі.

Інгрід дає поради як грати за певного персонажа, як противостояти персонажам, дає комбінації прийомів та їх описи і як їх ефективно використовувати. Використовується алгоритм Rag де в мене є велика кількість інформації яку я фільтрую і парсю і перереадю Інгрід як промпт разом з промптом користувача і вона формує відповідь. Є алгоритм по якому вона розуміє чи користувач розмовляє по темі, гри чи просто веде світську бесіду. Вона може давати markup прийомів

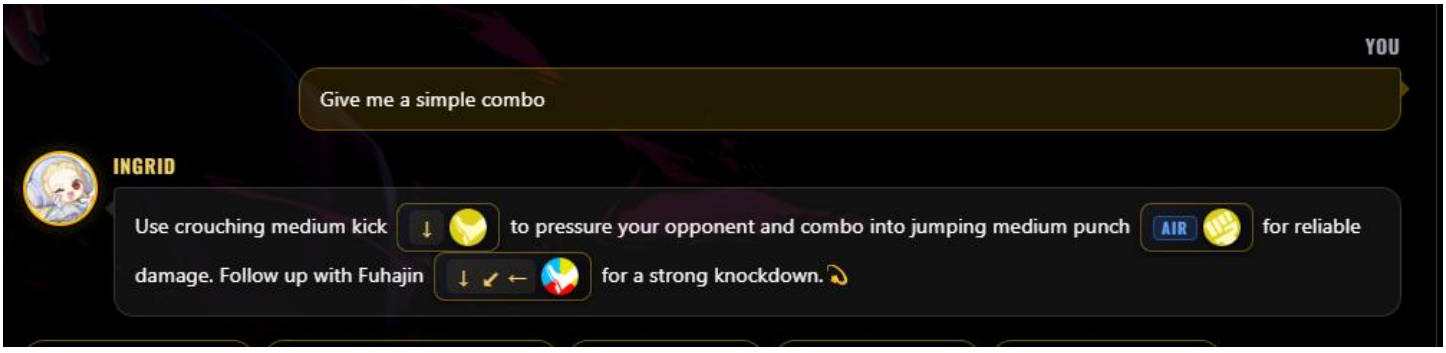
Тестові сценарії й результати:



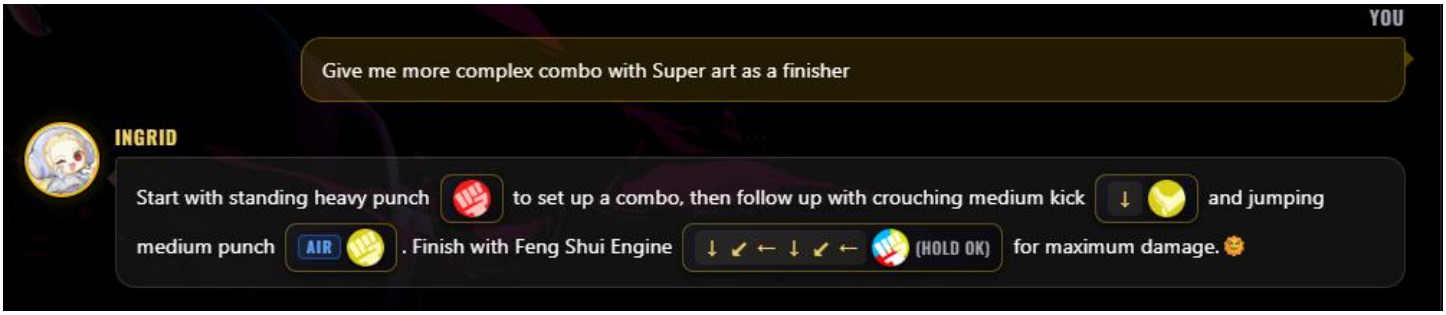
Інгрід дає загальну пораду як протистояти Каммі, граючи за Джурі



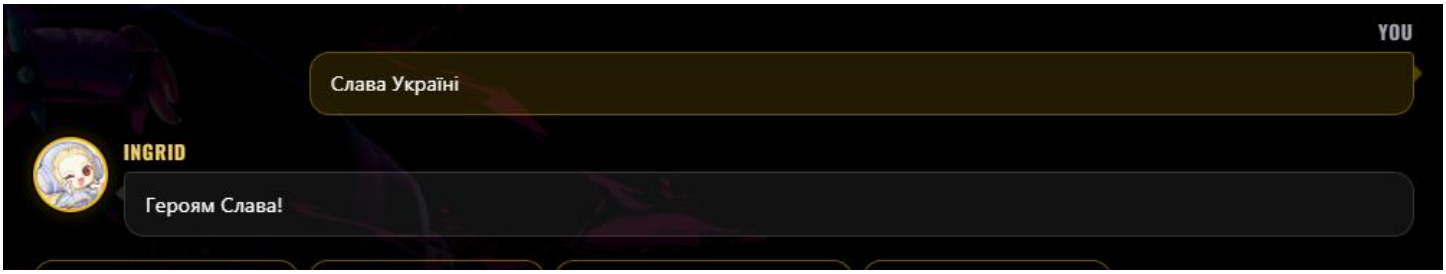
Дає пораду як покарати опонента



Рекомендація простого комбо

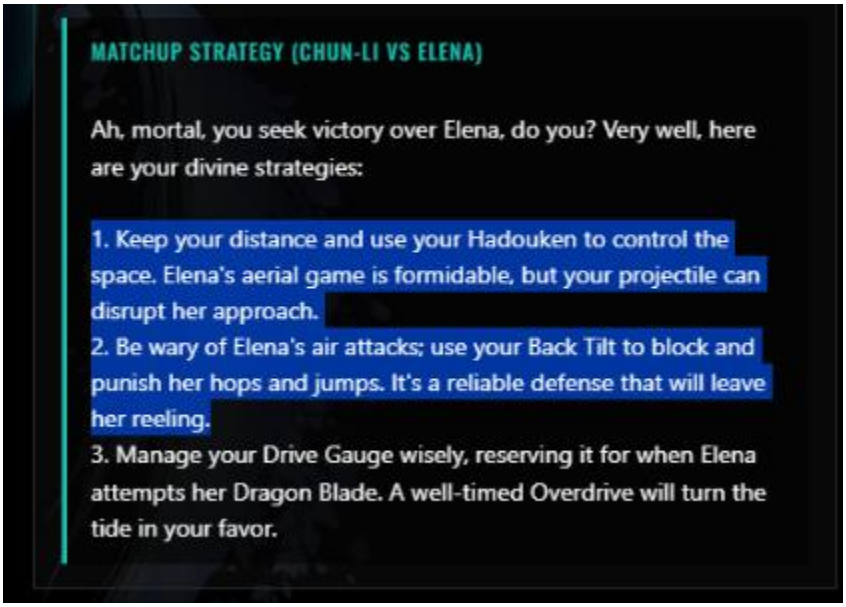


Більш складне комбо



Вона ще патріотка

Помилки з відповідями:



Колись помилялася і присвоювала персонажам не їхні прийоми, щоб пофіксити зібрав документ з прийомами і надаю цей список моделі. Вона тепер точно знає всю інформацію про всіх персонажів, а не додумує її

Висновок:

У цій лабораторній роботі я запускатив відкриті мовні моделі локально, без хмарних API: розібрався, чим відрізняються різні версії однієї моделі, як міряти швидкість, пам’ять і якість і як квантизація змінює ці показники.